This project simulates a healthcare data system in a hospital environment, focusing on data modeling, ETL processes, and analytical data transformation (OLTP to OLAP).

Business Process Flow

The system models the core hospital workflow as follows:

- Patient Registration Flow:
  - Patient → Registration → Medical Service → Diagnosis
- Prescription Flow:
  - Patient → Prescription → Drug Details
- Insurance Claim Flow:
  - Registration → CBG Claim
- Human Resources:
  - Medical Staff (Nakes) → Employee Data

Integrated Data Flow

Overall system integration:

Patient Registration → Medical Service → Diagnosis → Prescription → CBG Claim

This flow ensures that all patient-related activities are properly recorded and can be used for both operational (OLTP) and analytical (OLAP) purposes.

Area	**Temuan**	**Jumlah**	**Action**
Duplicate Primary Key	PK dc_resep_tebus duplicate	73287	Hapus duplicate + constraint PK
Duplicate Primary Key	PK dc_sebab_sakit duplicate	2226	Hapus duplicate + constraint PK
FK Integrity	Layanan tanpa pendaftaran (orphan id_pendaftaran)	116875	Masukkan ke table orphan_layanan untuk audit; skip saat load ke fact table OLAP; investigasi per jenis layanan dan dokter;

FK Integrity FK Integrity FK Integrity	Diagnosa tanpa layanan (orphan id_layanan_pendaftar an) Resep tanpa layanan(orphan id_layanan_pendaftar an) Resep Tebus R tanpa resep (orphan id_resep_tebus)	25 1 3722877	Masukkan ke table orphan_diagnosa untuk audit; skip saat load ke fact table OLAP Masukkan ke table orphan_resep untuk audit; skip saat load ke fact table OLAP Masukkan ke table orphan_resep_r untuk audit; skip saat load ke fact table OLAP
FK Integrity	Resep Tebus R Detail tanpa resep tebus r (orphan	444	Masukkan ke table orphan_resep_r_detai l untuk audit; skip

	id_resep_tebus_r)		saat load ke fact table OLAP
Logical Time	Pendaftaran Keluar Sebelum Waktu Daftar	7	Perbaiki data waktu_daftar = waktu_keluar
Logical Time	Layanan Periksa Sebelum Waktu Daftar	20	waktu_periksa yang lebih awal dari pendaftaran → di-set sama dengan waktu, waktu_status_keluar yang lebih awal

			dari waktu_periksa → di-set sama dengan waktu_periksa
Logical Time	Umur Tidak Masuk Akal	40	Set null untuk yang tidak valid
Business Logic	Diagnosa primer > 1 per layanan	1916	Update: pilih diagnosa primer terbaru berdasarkan waktu (ROW_NUMBER), set primer=0 untuk selain rn=1
Business Logic	Resep Tanpa Detail	129	Tambah kolom valid_detail; set valid_detail = 0 untuk resep tanpa detail
Business Logic	Detail Obat Harga Negatif	0	-
Business Logic	Jumlah Pakai 0 atau Negatif	61	Hapus data dengan jumlah_pakai <= 0
Klaim Check	Klaim Tanpa Pendaftaran	0	-
Klaim Check	Klaim Dengan Tagihan Negatif	0	-
Distribusi Data	Jumlah Pendaftaran Per Jenis	- Poliklinik: 189207 - IGD: 20937	Digunakan untuk melihat dominasi jenis layanan

Distribusi Data	Cara Bayar Paling Sering	- Tunai: 8812 - Asuransi: 266060 - Perusahaan: 14 - Karyawan: 1131	Mengidentifikasi metode pembayaran dominan
Distribusi Data	Status Klaim Distribusi	- Not Yet: 17491 - Added: 6449 - Saved: 795 - Grouper Stage 1: 1267 - Final: 184142	Monitoring proporsi klaim (approve, pending, reject, dll)
Data Type Standardization	Tipe data waktu_update di cbg_status_klaim belum konsisten	-	Ubah menjadi DATETIME
Data Type Standardization	Tipe data tanggal_daftar di dc_pasien belum konsisten	-	Ubah menjadi DATETIME
Data Type Standardization	Tipe data jam di dc_resep_tebus_r tidak konsisten	-	Ubah menjadi DATETIME
Value Standardization	string di dc_golongan_sebab_ sakit	Semua data yang isinya ‘NULL’	Diubah menjadi 'Tidak Diketahui'
Value Standardization	string di dc_pasien	Semua data yang isinya ‘NULL’	Diubah menjadi 'Tidak Diketahui'
Database Finalization	Database masih menggunakan nama staging	-	Rename farma_teknologi_oltp

dc_pasien

Area	Temuan	Jumlah	Action
Missing Value	tanggal_lahir NULL	1205	Diisi menggunakan median tanggal lahir
Missing Value	alergi NULL	2240701	Diisi dengan ‘Tidak Diketahui’
Missing Value	is_kronis NULL / 'NULL'	23581	Distandarisasi menjadi string 'NULL'
Missing Value	agama NULL/kosong	794	Diisi 'Lain-lain' + set ENUM & default
Missing Value	gol_darah NULL	298244	Diisi 'Unknown' + set ENUM & default

dc_pegawai

Area	Temuan	Jumlah	Action
Missing Value	agama NULL	11	Diisi 'Lain-lain' + set ENUM & default

dc_pendaftaran

Area	Temuan	Jumlah	Action
Missing Value	waktu_keluar NULL	72	Diisi dengan waktu_daftar
Missing Value	jenis_igd NULL	189183	Diisi 'Tidak Ada' + set ENUM & default

Missing Value	kondisi_keluar NULL	24	Diisi 'Hidup' + set ENUM & default

dc_resep_tebus

Area	Temuan	Jumlah	Action
Missing Value	status_obat_pulang NULL	10347	Diisi 'Tidak Diketahui' + set ENUM default
Missing Value	jenis_resep NULL	11168	Diisi 'Lain-lain'
Missing Value	asal_resep NULL	17352	Diisi 'Unknown'

dc_resep_tebus_r

Area	Temuan	Jumlah	Action
Missing Value	aturan_pakai NULL/'-'	257576	Diisi 'Tidak Diketahui'
Missing Value	timing NULL	231623	Diisi 'Tidak Diketahui' + set ENUM
Missing Value	pemberian NULL	383753	Diisi 'Tidak Diketahui' + set ENUM
Missing Value	jam NULL	383753	Diisi '00:00:00' + set default

dc_resep_tebus_r_detail

Area	Temuan	Jumlah	Action
Missing Value	formularium NULL	361989	Diisi 'Tidak' + set ENUM default

dc_nakes

Area	Temuan	Jumlah	Action
Missing Value	kode_spesialisasi NULL	25	Dokter tetap → 'UMU'; Non-dokter/tamu → 'NON
Missing Value	nama_spesialisasi NULL	25	Dokter tetap → 'Umum'; Non-dokter/tamu → 'Non Spesialis'

dc_layanan_pendaftaran

Area	Temuan	Jumlah	Action
Missing Value	status NULL	19363	Diisi 'Belum' + set ENUM default
Missing Value	tindak_lanjut NULL	16638	Diisi ‘Lain - lain’
Missing Value	jenis_lab NULL	354303	Diisi 'Tidak Ada' + set ENUM default
Missing Value	triase_primer NULL	334115	Diisi 0
Missing Value	waktu_periksa NULL		Diisi dengan waktu
Missing Value	waktu_status_keluar NULL	38281	Diisi dengan waktu

dc_golongan_sebab_sakit

Area	Temuan	Jumlah	Action
Missing Value	alias NULL	968	Diisi ‘Tidak Ada’
Missing Value	status NULL	968	Diisi 1

Missing Value	is_kronis null dan string ‘NULL’	715	Distandarisasi ‘NULL’

dc_diagnosa

Area	Temuan	Jumlah	Action
Missing Value	id_users NULL	126134	Diisi 0

cbg_status_klaim

Area	Temuan	Jumlah	Action
Missing Value	cbg_code NULL	17836	Diisi ‘Unknown’
Missing Value	status_klaim_id rg NULL	17397	Diisi 'tidak_diketahui' + set ENUM
Missing Value	upload_doc NULL/'-'	456	Distandarisasi 'tidak ada' + set ENUM
Missing Value	waktu_final NULL padahal status_klaim = ‘Final”	25840	Diisi dengan waktu_update
Missing Value	waktu_sent NULL padahal status_klaim_idrg = ‘send_klaim’	61288	Diisi dengan waktu_update

Perbandingan Struktur dan Constraint

Sebelum vs Sesudah Data Cleaning

Aspek	Sebelum	Sesudah	Dampak
ENUM Field	Banyak NULL dan value tidak standar	Distandarisasi ENUM (agama, gol_darah, is_kronis, dll)	Data lebih konsisten

Default Value	Tidak ada default	Ditambahkan default pada banyak field	Mencegah NULL baru
Field Kronis	Ada string ‘NULL’	Diganti ‘Tidak Diketahui’	Tidak Ambigu
Detail Resep Field Waktu	Ada resep tanda detail Banyak NULL pada waktu_final dan waktu_sent	Ditambahkan valid_detail Diisi berdasarkan business rule	Bisa filter data invalid Timeline klaim valid
Diagnosa Primer	Bisa > 1 per layanan	Dibersihkan jadi 1 primer saja	Konsistensi klinis
Missing Value	Banyak missing value di berbagai	0	Semua data terisi dan siap digunakan untuk

	tabel		analisis maupun modeling
Field Validasi	Tidak ada field validasi	Ditambahkan field validasi (valid_detail, valid_time, corrected_status_time)	Mempermudah filtering data valid untuk analitik
Tipe Data	Tidak konsisten dan campur string null	Seragam	Konsisten dan tidak ambigu

ERD OLTP link: https://dbdiagram.io/d/ERD-OLTP-69a50121a3f0aa31e1787e7e
ERD OLAP link: https://dbdiagram.io/d/OLAP-69a54332a3f0aa31e17e212d

Bagian 3
3.1 Create ERD OLTP Database
Untuk ERD OLTP ada di file ERD OLTP

3.2 Design OLAP Schema (Star Schema)

Menggunakan pendekatan Dimensional Modeling (Kimball). Alasan Pembentukan Star Schema:

1. Menggunakan Star Schema karena query agregasi lebih cepat, Join lebih sederhana, Cocok untuk analisis profitabilitas dan tren penyakit
2. Pemisahan Fact:
    - Fact_klaim → analisis keuangan dan profit
    - Fact_resep_detail → analisis pola peresepan
3. Time Dimension Terpisah, memungkinkan:
    - Drill down tahun → bulan → kuartal
    - Analisis tren musiman
4. Surrogate Key, digunakan untuk:
    - Menjaga integritas historis
    - Menghindari perubahan natural key

3.3 Implement OLAP Schema (ETL Process)

a. Extract

Data diambil dari:

- Dc_pendaftaran
- Dc_pasien
- Dc_layanan_pendaftaran
- Dc_diagnosa
- Dc_resep_tebus
- Cbg_status_klaim

b. Transform

Dilakukan:

- Perhitungan margin
- Perhitungan umur
- Pengelompokan umur
- Standarisasi boolean
- Penghilangan duplikasi

c. Load

Data dimasukkan ke:

- Dimension table terlebih dahulu
- Lalu fact table

Script ETL Process ada disini OLAP_Query

Struktur umum ETL:

1. Create Dimension

2. Insert Dimension
3. Create Fact
4. Insert Fact dengan join dimension

Bagian 4

Analisis 1: Profitabilitas Klaim vs Tagihan RS

1. Berdasarkan hasil query tahun 2025, diagnosa dengan margin terendah (kerugian terbesar) adalah: **Pneumonia due to other aerobic Gram-negative bacteria.** Link data diagnosa margin terendah: https://drive.google.com/file/d/1jkIIx1Y-BMXYShl0DLt6l_li5gYP7k41/view?usp=drive_link

   Dengan nilai:
   - Total Tagihan RS: Rp 2.626.1960
   - Total Klaim: Rp 53.404.600
   - Total Margin: Rp -27.142.640
2. Diagnosa dengan margin tertinggi adalah: **Other diseases of the blood and blood-forming organs and certain disorders involving the immune mechanism complicating pregnancy, childbirth and the puerperium**.
   Link data dengan margin tertinggi: https://drive.google.com/file/d/1ynn90zrH89wUyMVac6J9tW-C6q2FglpN/view?usp=drive_link
   Dengan nilai:
   - Total Tagihan: Rp 9.359.549
   - Total Klaim: Rp 2.169.500
   - Total Margin: Rp 7.190.049

Analisis 2: Tren Penyakit Berdasarkan Umur Pasien

1. Berdasarkan hasil query, pada setiap bulan di tahun 2025 ditemukan beberapa penyakit dengan jumlah kasus tertinggi.
   Link data penyakit paling sering per bulan 2025: https://drive.google.com/file/d/1Up_ihQW1E8wHtwSn_rFFLVOffzqgOTQL/view?usp=drive_link
   Data yang ditampilkan, terlihat bahwa:
   - Pada bulan Januari (bulan = 1), beberapa penyakit masing-masing hanya memiliki 1 kasus
   - Hal yang sama juga terlihat pada bulan Februari (bulan = 2), di mana jumlah kasus tertinggi per penyakit masih berada pada angka 1 kasus

Ini menunjukkan bahwa: Tidak terdapat dominasi penyakit tertentu secara signifikan pada bulan-bulan awal tahun 2025

2. Berdasarkan hasil query, distribusi diagnosa menunjukkan bahwa:
    - Kelompok 0-17 Tahun: Didominasi oleh penyakit yang umumnya berkaitan dengan Gangguan perkembangan, Penyakit bawaan (congenital), Infeksi ringan hingga sedang. Hal ini menunjukkan bahwa kelompok usia anak cenderung mengalami penyakit yang bersifat perkembangan atau bawaan lahir.
    - Kelompok 18-40 tahun: Pada kelompok ini, penyakit yang sering muncul umumnya berkaitan dengan Gangguan metabolik, Gangguan reproduksi, Cedera ringan hingga sedang. Kelompok ini termasuk usia produktif, sehingga variasi penyakit cukup beragam.
    - Kelompok 41-60 Tahun: Mulai terlihat dominasi penyakit kronis seperti Diabetes, Gangguan kardiovaskular, Gangguan metabolisme. Hal ini sesuai dengan karakteristik usia dewasa yang mulai mengalami peningkatan risiko penyakit degeneratif.
    - Kelompok 60+ Tahun: Didominasi oleh: Penyakit kronis, Komplikasi penyakit metabolik, Gangguan sistem pernapasan dan kardiovaskular. Kelompok lansia menunjukkan kecenderungan penyakit kronis yang lebih kompleks dan memerlukan biaya perawatan lebih tinggi.

Dari distribusi tersebut dapat disimpulkan bahwa:

- Semakin tinggi kelompok umur, semakin meningkat prevalensi penyakit kronis. -
Kelompok usia produktif (18–60 tahun) memiliki variasi diagnosa yang lebih luas.
- Kelompok lansia berpotensi memberikan beban klaim lebih besar karena kompleksitas penyakit.

Link data distribusi diagnosa:
https://drive.google.com/file/d/17hj6DKR1_5gsFRFDcVRNjWioU4xwJfFQ/view?usp=drive_link

Analisis 3: Analisa Data Pengklaiman

1. Berikut 10 CBG tercepat:

	cbg_code	jumlah_klaim	avg_durasi_jam
1	X-0-98-X	1	217.00
2	P-8-14-I	1	242.00
3	L-4-10-III	1	314.00
4	Q-5-33-0	1	605.00
5	X-0-07-X	1	743.00
6	E-4-12-I	1	894.00
7	I-4-12-I	5	1270.60
8	M-4-18-II	2	1273.50
9	I-3-13-0	158	1302.00
10	K-4-16-I	2	1393.50

Interpretasi:

- Durasi tercepat berada pada kisaran 217 jam (~9 hari).
- Sebagian besar kode tercepat hanya memiliki 1 klaim, sehingga belum cukup representatif untuk menilai konsistensi performa.
- Kode I-3-13-0 menarik perhatian karena memiliki 158 klaim dengan rata-rata durasi 1302 jam (~54 hari), menunjukkan performa relatif stabil dengan volume besar.

Link CBG:
https://drive.google.com/file/d/1Njro-PCjewRE9d-dBgy6RK-NxtoMIHG0/view?usp=drive_link

Artinya, klaim dengan kompleksitas rendah atau dokumen yang lengkap cenderung diproses lebih cepat.

2. Berikut CBG terlama

	cbg_code	jumlah_klaim	avg_durasi_jam
1	Z-4-12-III	1	8760.00
2	Z-3-26-0	1	8670.00
3	S-4-11-I	1	8501.00
4	D-3-10-0	1	8500.00
5	N-1-40-III	1	8453.00
6	M-1-02-I	1	8332.00
7	K-1-50-III	1	8088.00
8	J-3-17-0	1	7969.00
9	J-4-17-II	2	7958.50
10	L-1-30-I	6	7854.83

Interpretasi:

- Durasi terlama mencapai 8.760 jam (~365 hari), yang menunjukkan adanya klaim yang tertunda hampir 1 tahun.
- Mayoritas kode dengan durasi terlama hanya memiliki 1 klaim, sehingga kemungkinan terdapat kasus anomali atau keterlambatan administratif tertentu. - Kode L-1-30-I memiliki 6 klaim dengan rata-rata durasi 7.854 jam (~327 hari), yang menunjukkan potensi permasalahan sistemik pada kode tersebut.
-

3. Berdasarkan hasil agregasi data tahun 2025, ditemukan bahwa setiap bulan terdapat sejumlah klaim dengan status belum final yang menghasilkan nilai margin berbeda-beda. Margin dihitung menggunakan rumus:

   Margin = Tagihan RS - Klaim

   Interpretasi Umum Pola Bulanan
   Dari data bulanan terlihat bahwa:

   - Terdapat bulan dengan total margin negatif yang menunjukkan potensi kerugian pada klaim yang masih tertunda.
   - Beberapa bulan menunjukkan margin positif, artinya RS masih memiliki potensi profit, namun pencairannya tertunda.
   - Variasi nilai margin antar bulan menunjukkan adanya fluktuasi kualitas klaim atau perbedaan kompleksitas kasus.

Link profit/kerugian bulanan yang belum final:
https://drive.google.com/file/d/1FBo5J7mpzegVlSdifx_zvqVH96XD6zQY/view?usp=drive_lin

k

Tools dan Library yang Digunakan:
Dalam proses perancangan, pengolahan, dan analisis data, pengerjaan ini menggunakan beberapa tools utama yang mendukung pengelolaan database serta perancangan model data. **1. MySQL**
Sistem manajemen basis data yang digunakan dalam penelitian ini adalah MySQL. MySQL digunakan untuk:

- Penyimpanan database OLTP
- Proses cleaning data
- Pembuatan query analitis
- Implementasi ETL dari OLTP ke OLAP
- Perhitungan agregasi seperti margin, durasi klaim, dan distribusi penyakit

2. TablePlus
Sebagai database client, penelitian ini menggunakan TablePlus untuk:

- Menjalankan query SQL
- Melakukan eksplorasi tabel
- Mengecek hasil agregasi dan validasi data
- Mengelola koneksi database

TablePlus mempermudah proses debugging query dan visualisasi data secara langsung tanpa harus menggunakan command line.

3. dbdiagram.io
Untuk perancangan Entity Relationship Diagram (ERD) dan skema OLAP, digunakan platform dbdiagram.io.

Tool ini digunakan untuk:

- Mendesain ERD database OLTP
- Mendesain skema dimensional (Star Schema) OLAP
- Mendokumentasikan relasi antar tabel
- Menghasilkan diagram yang mudah dibaca dan dipresentasikan

dbdiagram.io dipilih karena mendukung format deklaratif (DBML) sehingga mempermudah dokumentasi struktur database secara sistematis.
Keterangan:
1. Data Quality Assessment: Semua query untuk data quality assessment ada disi
https://drive.google.com/file/d/1gVNx-26-cC2Qy2dsCR1JkWOGKor1eByB/view?usp=drive_l

i nk
2. Data Cleaning Process: Semua query untuk data cleaning ada disini
https://drive.google.com/file/d/1ANFo_7WFeN5P66FSqwHbhEq1b3Og8fnH/view?usp=drive_link
3. ERD OLAP
https://drive.google.com/file/d/11GyLOVMlVosH7YSMrwqTkZrwTq4fMkMI/view?usp=drive_link
4. ERD OLTP
https://drive.google.com/file/d/1M3xW9RSr3HziZeA_yKE9wpXC6ecyE6he/view?usp=drive_li nk
5. ETL Process/Pembuatan OLAP: Query untuk pembuatan OLAP ada disini
https://drive.google.com/file/d/1UJPhbIszKbK3zpYIZs8emxYcqKevYfeS/view?usp=drive_link
6. Database OLAP
https://drive.google.com/file/d/1Cm3YLrphmkF2o0KbKP-_OPrxbwdtrJue/view?usp=drive_link
7. Database OLTP
8. Query untuk menjawab bagian 4 ada disini semua
https://drive.google.com/file/d/13plz21u3bOxR8Tgt4afuV5YKW5e61jjw/view?usp=drive_link